

Информация, её представление и измерение

Понятие *информации* является наиболее сложным для понимания и обычно во вводных курсах информатики не определяется, принимается как исходное базовое понятие, понимается интуитивно, наивно. Часто это понятие отождествляется неправильным образом с понятием «сообщение».

Понятие «*информация*» имеет различные трактовки в разных предметных областях.

Рассмотрим это фундаментальное понятие информатики на основе понятия «*алфавит*» («алфавитный», формальный подход). Дадим формальное определение *алфавита*.

Алфавит – конечное множество различных знаков, символов, для которых определена операция **конкатенации** (приписывания, присоединения символа к символу или цепочке символов); с ее помощью по определенным правилам соединения символов и слов можно получать слова (цепочки знаков) и словосочетания (цепочки слов) в этом *алфавите* (над этим *алфавитом*).

Буквой или знаком называется любой элемент x *алфавита* X , где $x \in X$. Понятие знака неразрывно связано с тем, что им обозначается («со смыслом»), они вместе могут рассматриваться как пара элементов (x, y) , где x – сам знак, а y – обозначаемое этим знаком.

Пример. Примеры *алфавитов*: множество из десяти цифр, множество из знаков русского языка, точка и тире в азбуке Морзе и др. В *алфавите* цифр знак 5 связан с понятием «быть в количестве пяти элементов».

Конечная последовательность *букв алфавита* называется **словом** в *алфавите* (или над *алфавитом*).

Длиной $|p|$ *некоторого слова* p над *алфавитом* X называется число составляющих его букв.

Слово (обозначаемое символом $\emptyset$) имеющее нулевую *длину*, называется *пустым словом*: $|\emptyset| = 0$.

Множество различных *слов* над *алфавитом* X обозначим через $S(X)$ и назовем **словарным запасом (словарем)** *алфавита* (над *алфавитом*) X .

В отличие от конечного *алфавита*, словарный запас может быть и бесконечным.

Слова над некоторым заданным *алфавитом* и определяют так называемые *сообщения*.

Пример. Слова над *алфавитом* кириллицы – «Информатика», «инто», «иини», «и». Слова над *алфавитом* десятичных цифр и знаков арифметических операций – «1256», «23+78», «35–6+89», «4». Слова над *алфавитом* азбуки Морзе – «.», «. –», «– –».

В *алфавите* должен быть определен порядок следования *букв* (порядок типа «предыдущий элемент – последующий элемент»), то есть любой *алфавит* имеет упорядоченный вид $X = \{x_1, x_2, \dots, x_n\}$.

Таким образом, *алфавит* должен позволять решать задачу лексикографического (алфавитного) упорядочивания, или задачу расположения *слов* над этим *алфавитом*, в соответствии с порядком, определенным в *алфавите* (то есть по символам *алфавита*).

Информация – это некоторая упорядоченная последовательность *сообщений*, отражающих, передающих и увеличивающих наши знания.

Информация актуализируется с помощью различной формы *сообщений* – определенного вида сигналов, символов.

Информация по отношению к источнику или приемнику бывает трех типов: *входная*, *выходная* и *внутренняя*.

Информация по отношению к конечному результату бывает *исходная*, *промежуточная* и *результатирующая*.

Информация по ее изменчивости бывает *постоянная*, *переменная* и *смешанная*.

Информация по стадии ее использования бывает *первичная* и *вторичная*.

Информация по ее полноте бывает *избыточная*, *достаточная* и *недостаточная*.

Информация по доступу к ней бывает открытая и закрытая.

Есть и другие типы классификации информации.

Пример. В философском аспекте информация делится на мировоззренческую, эстетическую, религиозную, научную, бытовую, техническую, экономическую, технологическую.

Основные свойства информации:

- полнота;
- актуальность;
- адекватность;
- понятность;
- достоверность;
- массовость;
- устойчивость;
- ценность и др.

Информация – содержание сообщения, сообщение – форма информации .

Любые сообщения измеряются в байтах, килобайтах, мегабайтах, гигабайтах, терабайтах, петабайтах и эксабайтах, а кодируются, например, в компьютере, с помощью алфавита из нулей и единиц, записываются и реализуются в ЭВМ в битах.

Приведем основные соотношения между единицами измерения сообщений:

1 бит (binary digit – двоичное число) = 0 или 1,

1 байт 8 бит,

1 килобайт (1Кб) = 2^{13} бит,

1 мегабайт (1Мб) = 2^{23} бит,

1 гигабайт (1Гб) = 2^{33} бит,

1 терабайт (1Тб) = 2^{43} бит,

1 петабайт (1Пб) = 2^{53} бит,

1 эксабайт (1Эб) = 2^{63} бит.

Пример. Найти неизвестные x и y, если верны соотношения:

$128^y (К) = 32^x (бит);$

$2^x (М) = 2^y (байт).$

Выравниваем единицы измерения информации:

$2^{7y} (К) = 2^{7y+13} (бит);$

$2^x (М) = 2^{x+20} (байт).$

Подставляя в уравнения и отбрасывая размерности информации, получаем:

$$2^{7y+13} = 2^{5x}$$

$$2^{x+20} = 2^y$$

Отсюда получаем систему двух алгебраических уравнений:

$$\begin{cases} 7y + 13 = 5x \\ x + 20 = y \end{cases}$$

или, решая эту систему, окончательно получаем, $x = -76,5$, $y = -56,5$.

Для измерения информации используются различные подходы и методы, например, с использованием меры информации по Р. Хартли и К. Шеннону.

Количество информации – число, адекватно характеризующее разнообразие (структурированность, определенность, выбор состояний и т.д.) в оцениваемой системе. Количество информации часто оценивается в битах, причем такая оценка может выражаться и в долях бит (так как речь идет не об измерении или кодировании сообщений).

Мера информации – критерий оценки количества информации. Обычно она задана некоторой неотрицательной функцией, определенной на множестве событий и являющейся аддитивной, то есть мера конечного объединения событий (множеств) равна сумме мер каждого события.

Рассмотрим различные меры информации.

Возьмем меру Р. Хартли. Пусть известны N состояний системы S (N опытов с различными, равновозможными, последовательными состояниями системы). Если каждое состояние системы закодировать двоичными кодами, то длину кода d необходимо выбрать так, чтобы число всех различных комбинаций было бы не меньше, чем N :

$$2^d \geq N$$

Логарифмируя это неравенство, можно записать:

$$d \geq \log_2 N$$

Наименьшее решение этого неравенства или мера разнообразия множества состояний системы задается *формулой Р. Хартли*:

$$H = \log_2 N \text{ (бит)}.$$

Пример. Чтобы определить состояние системы из четырех возможных состояний, то есть получить некоторую *информацию* о системе, необходимо задать 2 вопроса. Первый вопрос, например: «Номер состояния больше 2?». Узнав ответ («да», «нет»), мы увеличиваем суммарную *информацию* о системе на 1 *бит* ($I = \log_2 2$). Далее необходим еще один уточняющий вопрос, например, при ответе «да»: «Состояние – номер 3?». Итак, количество *информации* равно 2 *битам* ($I = \log_2 4$). Если система имеет n различных состояний, то максимальное количество *информации* равно $I = \log_2 n$.

Если во множестве $X = \{x_1, x_2, \dots, x_n\}$ искать произвольный элемент, то для его нахождения (по Хартли) необходимо иметь не менее $\log_2 n$ (единиц) *информации*.

Уменьшение H говорит об уменьшении разнообразия состояний N системы.

Увеличение H говорит об увеличении разнообразия состояний N системы.

Мера Хартли подходит лишь для идеальных, абстрактных систем, так как в реальных системах состояния системы неодинаково осуществимы (неравновероятны).

Для таких систем используют более подходящую меру К. Шеннона. Мера Шеннона оценивает *информацию* отвлеченно от ее смысла:

$$I = - \sum_{i=1}^n p_i \log_2 p_i$$

где n – число состояний системы; p_i – вероятность (относительная частота) перехода системы в i -е состояние, а сумма всех p_i должна равняться 1.

Если все состояния рассматриваемой системы равновозможны, равновероятны, то есть $p_i = 1/n$, то из *формулы Шеннона* можно получить (как частный случай) *формулу Хартли*:

$$I = \log_2 n.$$

Пример. Если положение точки в системе из 10 клеток известно, например если точка находится во второй клетке, то есть

$$p_i = 0, i = 1, 3, 4, \dots, 10, p_2 = 1,$$

то тогда получаем количество информации, равное нулю:

$$I = \log_2 1 = 0.$$

Обозначим величину:

$$f_i = -n \log_2 p_i.$$

Тогда из *формулы К. Шеннона* следует, что количество информации I можно понимать как среднеарифметическое величин f_i , то есть величину f_i можно интерпретировать как информационное содержание символа *алфавита* с индексом i и величиной p_i вероятности появления этого символа в любом *сообщении (слове)*, передающем *информацию*.

в термодинамике известен так называемый коэффициент Больцмана

$$k = 1.38 \cdot 10^{-16} \text{ (эрг/град)}$$

и выражение (*формула Больцмана*) для энтропии или *меры хаоса* в термодинамической системе:

$$S = -k \sum_{i=1}^n p_i \ln p_i$$

Сравнивая выражения для I и S, можно заключить, что величину I можно понимать как энтропию из-за нехватки *информации* в системе (о системе).

Основное функциональное соотношение между энтропией и *информацией* имеет вид:
 $I + S(\log_2 e)/k = \text{const}$.

Из этой формулы следуют важные выводы:

1. увеличение меры Шеннона свидетельствует об уменьшении энтропии (увеличении порядка) системы;
2. уменьшение меры Шеннона свидетельствует об увеличении энтропии (увеличении беспорядка) системы.

Положительная сторона *формулы Шеннона* – ее отвлеченность от смысла *информации*. Кроме того, в отличие от *формулы Хартли*, она учитывает различность состояний, что делает ее пригодной для практических вычислений. Основная отрицательная сторона *формулы Шеннона* – она не распознает различные состояния системы с одинаковой вероятностью.

Методы получения *информации* можно разбить на три большие группы.

1. Эмпирические методы или методы получения эмпирических данных.
2. Теоретические методы или методы построения различных теорий.
3. Эмпирико-теоретические методы (смешанные) или методы построения теорий на основе полученных эмпирических данных об объекте, процессе, явлении.

Охарактеризуем кратко эмпирические методы.

1. *Наблюдение* – сбор первичной *информации* об объекте, процессе, явлении.
2. *Сравнение* – обнаружение и соотнесение общего и различного.
3. *Измерение* – поиск с помощью измерительных приборов эмпирических фактов.
4. *Эксперимент* – преобразование, рассмотрение объекта, процесса, явления с целью выявления каких-то новых свойств.

Кроме классических форм их реализации, в последнее время используются опрос, интервью, тестирование и другие.

Охарактеризуем кратко эмпирико-теоретические методы.

1. *Абстрагирование* – выделение наиболее важных для исследования свойств, сторон исследуемого объекта, процесса, явления и игнорирование несущественных и второстепенных.
2. *Анализ* – разъединение целого на части с целью выявления их связей.
3. *Декомпозиция* – разъединение целого на части с сохранением их связей с окружением.
4. *Синтез* – соединение частей в целое с целью выявления их взаимосвязей.
5. *Композиция* – соединение частей целого с сохранением их взаимосвязей с окружением.
6. *Индукция* – получение знания о целом по знаниям о частях.
7. *Дедукция* – получение знания о частях по знаниям о целом.
8. *Эвристики, использование эвристических процедур* – получение знания о целом по знаниям о частях и по наблюдениям, опыту, интуиции, предвидению.
9. *Моделирование (простое моделирование)*, использование приборов – получение знания о целом или о его частях с помощью модели или приборов.
10. *Исторический метод* – поиск знаний с использованием предыстории, реально существовавшей или же мыслимой.
11. *Логический метод* – поиск знаний путем воспроизведения частей, связей или элементов в мышлении.
12. *Макетирование* – получение *информации* по макету, представлению частей в упрощенном, но целостном виде.

13. *Актуализация* – получение *информации* с помощью перевода целого или его частей (а следовательно, и целого) из статического состояния в динамическое состояние.
14. *Визуализация* – получение *информации* с помощью наглядного или визуального представления состояний объекта, процесса, явления.

Кроме указанных классических форм реализации теоретико-эмпирических методов часто используются и мониторинг (система наблюдений и анализа состояний), деловые игры и ситуации, экспертные оценки (экспертное оценивание), имитация (подражание) и другие формы.

Охарактеризуем кратко теоретические методы.

1. *Восхождение от абстрактного к конкретному* – получение знаний о целом или о его частях на основе знаний об абстрактных проявлениях в сознании, в мышлении.
2. *Идеализация* – получение знаний о целом или его частях путем представления в мышлении целого или частей, не существующих в действительности.
3. *Формализация* – получение знаний о целом или его частях с помощью языков искусственного происхождения (формальное описание, представление).
4. *Аксиоматизация* – получение знаний о целом или его частях с помощью некоторых аксиом (не доказываемых в данной теории утверждений) и правил получения из них (и из ранее полученных утверждений) новых верных утверждений.
5. *Виртуализация* – получение знаний о целом или его частях с помощью искусственной среды, ситуации.

Пример. Для построения модели планирования и управления производством в рамках страны, региона или крупной отрасли нужно решить следующие проблемы:

1. определить структурные связи, уровни управления и принятия решений, ресурсы; при этом чаще используются методы наблюдения, сравнения, измерения, эксперимента, анализа и синтеза, дедукции и индукции, эвристический, исторический и логический методы, макетирование и др.;
2. определить гипотезы, цели, возможные проблемы планирования; наиболее используемые методы – наблюдение, сравнение, эксперимент, абстрагирование, анализ, синтез, дедукция, индукция, эвристический, исторический, логический и др.;
3. конструирование эмпирических моделей; наиболее используемые методы – абстрагирование, анализ, синтез, индукция, дедукция, формализация, идеализация и др.;
4. поиск решения проблемы планирования и просчет различных вариантов, директив планирования, поиск оптимального решения; используемые чаще методы – измерение, сравнение, эксперимент, анализ, синтез, индукция, дедукция, актуализация, макетирование, визуализация, виртуализация и др.

Суть задачи управления системой – отделение ценной *информации* от «шумов» (бесполезного, иногда даже вредного для системы возмущения *информации*) и выделение *информации*, которая позволяет этой системе существовать и развиваться.

Информационная система – это система, в которой элементы, структура, цель, ресурсы рассматриваются на информационном уровне (хотя, естественно, имеются и другие уровни рассмотрения).

Информационная среда – это среда (система и ее окружение) из взаимодействующих *информационных систем*, включая и *информацию*, актуализируемую в этих системах.

Установление отношений и связей, описание их формальными средствами, языками, разработка соответствующих описаниям моделей, методов, алгоритмов, создание и актуализация технологий, поддерживающих эти модели и методы, и составляет основную задачу информатики как науки, образовательной области, сферы человеческой деятельности.

Информатику можно определить как науку, изучающую неизменные сущности (инварианты) информационных процессов, которые протекают в различных предметных областях, в обществе, в познании, в природе.