


Высокопроизводительные системы и их классификация

Примеры параллельных вычислительных систем

- **Суперкомпьютер** – специализированная вычислительная машина, значительно превосходящая по своим техническим параметрам и скорости вычислений большинство существующих в мире компьютеров.
- Как правило, современные суперкомпьютеры представляют собой большое число высокопроизводительных серверных компьютеров, соединённых друг с другом локальной высокоскоростной магистралью для достижения максимальной производительности в рамках подхода распараллеливания вычислительной задачи.

- В общеупотребительный лексикон термин «суперкомпьютер» вошёл благодаря распространённости компьютерных систем Сеймура Крэя:
- CDC 6600 (1963)
- CDC 7600 (1969)
- Cray-1 (1975)
- Cray-2 (1985)
- Cray-3 (1988)
- Cray-4 (1994)



- Начиная с 1993, суперкомпьютеры ранжируют в списке Top500.
- Список составляется на основе теста LINPACK по решению системы линейных алгебраических уравнений, являющейся общей задачей для численного моделирования.
- На ноябрь 2018 г. лидирующую позицию занимает Summit (США, Oak Ridge National Laboratory)
- <https://www.top500.org/lists/>

Примеры параллельных вычислительных систем

- **Кластер** – группа компьютеров, объединённых высокоскоростными каналами связи, представляющая с точки зрения пользователя единый аппаратный ресурс.
- Кластер – слабо связанная совокупность нескольких вычислительных систем, работающих совместно для выполнения общих приложений, и представляющихся пользователю единой системой.

Кластеры

Согласно одному из первых архитекторов кластерной технологии Грегори Пфистеру (Gregory Pfister):

«Кластер — это разновидность параллельной или распределённой системы, которая:

- состоит из нескольких связанных между собой компьютеров;
- используется как единый, унифицированный компьютерный ресурс».

Обычно различают следующие основные виды кластеров:

- отказоустойчивые кластеры (High-availability clusters, HA, кластеры высокой доступности),
- кластеры с балансировкой нагрузки (Load balancing clusters),
- вычислительные кластеры (High performance computing clusters, HPC)
- системы распределенных вычислений.

Отказоустойчивый кластер

- Отказоустойчивый кластер (англ. High-Availability cluster, HA cluster) — кластер, спроектированный в соответствии с методом обеспечения высокой доступности и гарантирующий минимальное время простоя за счёт аппаратной избыточности.
- Отказоустойчивые кластеры обычно используют специальный сигнал («пульс», англ. heartbeat), который используется для мониторинга состояния и статуса каждого узла в кластере.
- Отказоустойчивые кластеры часто используются для поддержки важных баз данных и бизнес-приложений обслуживания клиентов, таких как сайты электронной коммерции.

Отказоустойчивые кластеры и системы вообще строятся по трем основным принципам:

- **с холодным резервом** или **активный/пассивный**. Активный узел выполняет запросы, а пассивный ждет его отказа и включается в работу, когда таковой произойдет. Пример — резервные сетевые соединения, в частности, Алгоритм связующего дерева. Например связка DRBD и HeartBeat.
- **с горячим резервом** или **активный/активный**. Все узлы выполняют запросы, в случае отказа одного нагрузка перераспределяется между оставшимися. То есть кластер распределения нагрузки с поддержкой перераспределения запросов при отказе. Примеры — практически все кластерные технологии, например, Microsoft Cluster Server. OpenSource проект OpenMosix.
- **с модульной избыточностью**. Применяется только в случае, когда простой системы совершенно недопустим. Все узлы одновременно выполняют один и тот же запрос (либо части его, но так, что результат достижим и при отказе любого узла), из результатов берется любой. Необходимо гарантировать, что результаты разных узлов всегда будут одинаковы (либо различия гарантированно не повлияют на дальнейшую работу). Примеры — RAID и Triple modular redundancy.

Кластеры с балансировкой нагрузки (Network Load Balancing, NLB)

- Принцип их действия строится на распределении запросов через один или несколько входных узлов, которые перенаправляют их на обработку в остальные, вычислительные узлы. Первоначальная цель такого кластера — производительность, однако, в них часто используются также и методы, повышающие надёжность.
- Подобные конструкции называются серверными фермами.
- Программное обеспечение (ПО) может быть как коммерческим (OpenVMS, MOSIX, Platform LSF HPC, Solaris Cluster, Moab Cluster Suite, Maui Cluster Scheduler), так и бесплатным (OpenMosix, Sun Grid Engine, Linux Virtual Server).

Вычислительные кластеры

- Вычислительные кластеры позволяют уменьшить время расчетов, по сравнению с одиночным компьютером, разбивая задание на параллельно выполняющиеся ветки, которые обмениваются данными по связывающей сети.
- Одна из типичных конфигураций — набор компьютеров, собранных из общедоступных компонентов, с установленной на них операционной системой Linux, и связанных сетью Ethernet, Myrinet, InfiniBand или другими относительно недорогими сетями. Такую систему принято называть кластером Beowulf.
- Специально выделяют высокопроизводительные кластеры (Обозначаются англ. аббревиатурой HPC Cluster — High-performance computing cluster).

Системы распределенных вычислений (grid)

- Такие системы не принято считать кластерами, но их принципы в значительной степени сходны с кластерной технологией. Их также называют grid-системами.
- Главное отличие — низкая доступность каждого узла, то есть невозможность гарантировать его работу в заданный момент времени (узлы подключаются и отключаются в процессе работы), поэтому задача должна быть разбита на ряд независимых друг от друга процессов. Такая система, в отличие от кластеров, не похожа на единый компьютер, а служит упрощённым средством распределения вычислений. Нестабильность конфигурации, в таком случае, компенсируется большим числом узлов.

Высокопроизводительные вычисления в России

Текущий рейтинг (Редакция №29 от 24.09.2018)

№	Название Место установки	Узлов Проц. Ускор.	Архитектура: кол-во узлов: конфигурация узла сеть: вычислительная / сервисная / транспортная	Fmax Fpeak (Тфлоп/ с)	Разработчик Область применения
1	«Ломоносов-2» Московский государственный университет имени М.В.Ломоносова	1696 1696 1856	160: CPU: 1x Intel Xeon Gold 6126, 96 GB RAM Acc: 2x NVIDIA Tesla P100 1536: CPU: 1x Intel Xeon E5-2697v3, 64 GB RAM Acc: 1x NVIDIA Tesla K40M FDR Infiniband / Gigabit Ethernet / FDR Infiniband	2478.0 4946.79	Т-Платформы Наука и образование
2	ФГБУ 'ГВЦ Росгидромета'	976 1952 н/д	976: CPU: 2x Intel Xeon E5-2697v4, 128 GB RAM Aries / Aries + Gigabit Ethernet / Aries + Infiniband	1200.35 1293.0	Т-Платформы Cray
3	«Ломоносов» Московский государственный университет имени М.В.Ломоносова	6199 12406 2130	4: CPU: 4x Intel Xeon X7560, 512 GB RAM 288: CPU: 2x Intel Xeon E5630, 24 GB RAM Acc: 2x NVIDIA Tesla X2070 777: CPU: 2x Intel Xeon E5630, 12 GB RAM Acc: 2x NVIDIA Tesla X2070 30: CPU: 2x IBM PowerXCell 8i, 16 GB RAM 40: CPU: 2x Intel Xeon X5670, 48 GB RAM 640: CPU: 2x Intel Xeon X5670, 24 GB RAM 260: CPU: 2x Intel Xeon X5570, 24 GB RAM 4160: CPU: 2x Intel Xeon X5570, 12 GB RAM QDR Infiniband / Gigabit Ethernet / Gigabit Ethernet	901.9 1700.21	Т-Платформы Исследования
4	НИЦ "Курчатовский институт"	535 1070 365	364: CPU: 2x Intel Xeon E5-2680v3, 128 GB RAM 23: CPU: 2x Intel Xeon E5-2680v3, 128 GB RAM Acc: 3x NVIDIA Tesla K80 148: CPU: 2x Intel Xeon E5-2650v2, 128 GB RAM Acc: 2x NVIDIA Tesla K80 FDR Infiniband / Gigabit Ethernet / Gigabit Ethernet	755.53 1100.55	НИЦ "Курчатовский Институт" SuperMicro Борлас Т-Платформы Наука и образование



Организаторы
рейтинга:



Классификация вычислительных систем (систематика Флинна)

	Один поток инст- рукций	Несколько пото- ков инструкций
Один поток дан- ных	SISD	MISD
Несколько пото- ков данных	SIMD	MIMD

- **SISD (Single Instruction Single Data):** это обычные последовательные компьютеры. Программа принимает один поток данных и выполняет один поток инструкций по обработке этих данных. Иными словами, инструкции выполняются последовательно, и каждая инструкция оперирует минимальным количеством данных (например, сложение двух чисел).

- **MISD (Multiple Instruction Single Data):** разные потоки инструкций выполняются с одними и теми же данными. Обычно такие системы не приводят к ускорению вычислений, так как разные инструкции оперируют одними и теми же данными, в результате на выходе системы получается один поток данных.
- К таким системам относят различные системы дублирования и защиты от сбоев, когда, например, несколько процессоров дублируют вычисления друг друга для надёжности. Иногда к этой категории относят конвейерные архитектуры. Среди процессоров производства Intel, конвейер присутствует начиная с процессора Pentium.

- **SIMD (Single Instruction Multiple Data):** один поток инструкций выполняет вычисления одновременно с разными данными. Например, выполняется сложение одновременно восьми пар чисел. Такие компьютеры называются векторными, так как подобные операции выполняются аналогично операциям с векторами (когда, например, сложение двух векторов означает одновременное сложение всех их компонентов). Зачастую векторные инструкции присутствуют в дополнение к обычным «скалярным» инструкциям, и называются SIMD-расширением (или векторным расширением).
- Примеры популярных SIMD-расширений: MMX, 3DNow!, SSE и др.

- **MIMD (Multiple Instruction Multiple Data):** разные потоки инструкций оперируют различными данными. Это системы наиболее общего вида, поэтому их проще всего использовать для решения различных параллельных задач.
- MIMD-системы, в свою очередь, принято разделять (классификация Джонсона) на системы с общей памятью (несколько вычислителей имеют общую память) и системы с распределенной памятью (каждый вычислитель имеет свою память; вычислители могут обмениваться данными). Кроме того, существуют системы с неоднородным доступом к памяти (NUMA) — в которых доступ к памяти других вычислителей существует, но он значительно медленнее, чем доступ к «своей» памяти.

Системы с общей памятью

Преимущества:

- Не требуется обмен данными
- Для таких систем просто писать программы. Кроме того, возможно полностью автоматическое распараллеливание программы компилятором.
- Компактность систем

Недостатки:

- Проблема совместного доступа к памяти
- Проблема синхронности кэшей
- Проблема медленного обращения к оперативной памяти и её ограниченного объёма
- Проблема масштабируемости

Системы с распределённой памятью

Преимущества:


- Простота и дешевизна построения
- Эффективное решение задач, требующих малого обмена данными.
- Возможность решать задачи, требующие очень больших объёмов оперативной памяти.
- Возможность масштабирования.

Недостатки:

- Проблема обмена данными.
- Сложное программирование.
- Большой размер систем и большое энергопотребление.

Гибридные системы

- Многие современные системы представляют собой иерархию описанных выше систем.
- Например, современные процессоры являются конвейерными процессорами, и имеют набор векторных инструкций (MMX, SSE и т.п.), позволяющих выполнять одновременные вычисления с разными данными.
- Кроме того, процессор может иметь два ядра, или может быть несколько процессоров в компьютере. Таким образом, на этом уровне система представляет собой систему с общей памятью. Затем можно соединить несколько таких компьютеров в кластер, образовав новый уровень иерархии: систему с распределённой памятью.



- Классификация архитектур вычислительных систем нужна для того, чтобы понять особенности работы той или иной архитектуры, но она не является достаточно детальной, поэтому следует вводить более детальную классификацию, которая связана с различными архитектурами ЭВМ и с используемым оборудованием.

SMP-архитектура

- SMP (symmetric multiprocessing) – ***симметричная многопроцессорная архитектура***. Главной особенностью систем с архитектурой SMP является наличие *общей физической памяти*, разделяемой всеми процессорами.



SMP-архитектура

- *SMP*-система строится на основе высокоскоростной системной шины (*SGI PowerPath*, *Sun Gigaplane*, *DEC TurboLaser*), к слотам которой подключаются функциональные блоки типов: процессоры (ЦП), подсистема ввода/вывода (*I/O*) и т. п.
- Для подсоединения к модулям *I/O* используются уже более медленные шины (*PCI*, *VME64*). Наиболее известными *SMP*-системами являются *SMP*-серверы и рабочие станции на базе процессоров Intel (*IBM*, HP, Compaq, Dell, ALR, Unisys, DG, Fujitsu и др.)

Основные преимущества *SMP*-систем:

- простота и универсальность для программирования. Архитектура *SMP* не накладывает ограничений на модель программирования, используемую при создании приложения: обычно используется модель параллельных ветвей, когда все процессоры работают независимо друг от друга. Однако можно реализовать и модели, использующие межпроцессорный обмен. Использование *общей памяти* увеличивает *скорость* такого обмена, пользователь также имеет доступ сразу ко всему объему памяти. Для *SMP*-систем существуют довольно эффективные средства автоматического распараллеливания;
- простота эксплуатации. Как правило, *SMP*-системы используют систему кондиционирования, основанную на воздушном охлаждении, что облегчает их техническое обслуживание;
- относительно невысокая цена.


Недостатки:

- системы с *общей памятью* плохо масштабируются.

MPP-архитектура

- MPP архитектура (massive parallel processing) - **массивно-параллельная архитектура**.
- Главная особенность такой архитектуры состоит в том, что память физически разделена. В этом случае система строится из отдельных модулей, содержащих процессор, локальный банк операционной памяти (ОП), два коммуникационных процессора (рутера) или сетевой адаптер, иногда - жесткие диски и/или другие устройства ввода/вывода. Один рутер используется для передачи команд, другой - для передачи данных. По сути, такие модули представляют собой полнофункциональные компьютеры.

МРР-архитектура



MPP-архитектура

- Системы с распределенной памятью идеально подходят для параллельного выполнения независимых программ, поскольку при этом каждая программа выполняется на своем узле и никаким образом не влияет на выполнение других программ.
- Однако при разработке параллельных программ приходится учитывать более сложную, чем в SMP системах, организацию памяти.

Оперативная память в MPP системах имеет 3-х уровневую структуру:


- кэш-память процессора;
- локальная оперативная память узла;
- оперативная память других узлов.

- Системами с раздельной памятью являются суперкомпьютеры MBC-1000, *IBM RS/6000 SP*, *SGI/CRAY T3E*, системы *ASCI*, *Hitachi SR8000*, системы *Parsytec*.
- Машины последней серии *CRAY T3E* от *SGI*, основанные на базе процессоров *Dec Alpha 21164* с пиковой производительностью 1200 Мфлопс (*CRAY T3E-1200*), способны масштабироваться до 2048 процессоров.
- При работе с *MPP*-системами используют так называемую *Massive Passing Programming Paradigm* – парадигму программирования с передачей данных (*MPI*, *PVM*, *BSPlib*).

Гибридная архитектура NUMA

- Главная особенность *гибридной архитектуры* NUMA (nonuniform memory access) – *неоднородный доступ к памяти*.
- *Гибридная архитектура* совмещает достоинства систем с *общей памятью* и относительную дешевизну систем с *раздельной памятью*. Суть этой архитектуры – в особой организации памяти, а именно: память физически распределена по различным частям системы, но логически она является *общей*, так что пользователь видит *единое адресное пространство*. Система построена из однородных базовых модулей (плат), состоящих из небольшого числа процессоров и блока памяти. Модули объединены с помощью *высокоскоростного коммутатора*.

Структурная схема компьютера с гибридной сетью



Организация когерентности многоуровневой иерархической памяти

- Понятие *когерентности кэшей* описывает тот факт, что все центральные процессоры получают одинаковые значения одних и тех же переменных в любой момент времени.
- Поскольку *кэш-память* принадлежит отдельному компьютеру, а не всей многопроцессорной системе в целом, данные, попадающие в *кэш* одного компьютера, могут быть недоступны другому.
- Чтобы этого избежать, следует провести синхронизацию информации, хранящейся в *кэш-памяти* процессоров.

Для обеспечения когерентности кэшей существует несколько возможностей:

- использовать механизм отслеживания шинных запросов (snoopy bus protocol), в котором кэши отслеживают переменные, передаваемые к любому из центральных процессоров и при необходимости модифицируют собственные копии таких переменных;
- выделять специальную часть памяти, отвечающую за отслеживание достоверности всех используемых копий переменных.

PVP-архитектура

- **PVP (Parallel Vector Process) – параллельная архитектура с векторными процессорами**
- Основным признаком PVP-систем является наличие специальных векторно-конвейерных процессоров, в которых предусмотрены команды однотипной обработки векторов независимых данных, эффективно выполняющиеся на *конвейерных функциональных устройствах*.
- Как правило, несколько таких процессоров (1-16) работают одновременно с общей памятью (аналогично *SMP*) в рамках многопроцессорных конфигураций. Несколько узлов могут быть объединены с помощью коммутатора (аналогично *MPP*).
Поскольку передача данных в векторном формате осуществляется намного быстрее, чем в скалярном (максимальная скорость может составлять 64 Гбайт/с, что на 2 порядка быстрее, чем в скалярных машинах), то проблема взаимодействия между потоками данных при распараллеливании становится несущественной.

Примеры машин РVP-архитектуры:

- **CRAY X1, SMP** -архитектура. Пиковая производительность системы в стандартной конфигурации может составлять десятки терафлопс.



- **Fujitsu-VPP5000 (vector parallel processing), MPP-архитектура.** Производительность одного процессора составляет 9.6 Гфлопс, пиковая производительность системы может достигать 1249 Гфлопс, максимальная емкость памяти – 8 Тбайт.



- **Парадигма программирования** на RVP-системах предусматривает векторизацию циклов (для достижения разумной производительности одного процессора) и их распараллеливание (для одновременной загрузки нескольких процессоров одним приложением).
- На практике рекомендуется выполнять следующие процедуры:
 1. Производить векторизацию вручную, чтобы перевести задачу в матричную форму. При этом, в соответствии с длиной вектора, размеры матрицы должны быть кратны 128 или 256;
 2. Работать с векторами в виртуальном пространстве, разлагая искомую функцию в ряд и оставляя число членов ряда, кратное 128 или 256.

Кластер

- ***Кластер*** представляет собой два или более компьютеров (часто называемых узлами), объединяемых при помощи *сетевых технологий* на базе шинной архитектуры или коммутатора и предстающих перед пользователями в качестве единого информационно-вычислительного ресурса. В качестве узлов *кластера* могут быть выбраны серверы, рабочие станции и даже обычные персональные компьютеры. Узел характеризуется тем, что на нем работает единственная копия операционной системы.

- **Кластеризация** может осуществляться на разных уровнях компьютерной системы, включая аппаратное обеспечение, операционные системы, программы-утилиты, системы управления и приложения.
- Чем больше уровней системы объединены кластерной технологией, тем выше надежность, масштабируемость и управляемость кластера.


Типы кластеров

(Я. Радаевский и Д.Эдлайн)


- **Класс I.** Класс машин строится целиком из стандартных деталей, которые продают многие поставщики компьютерных компонентов (низкие цены, простое обслуживание, аппаратные компоненты доступны из различных источников).
- **Класс II.** Система имеет эксклюзивные или не слишком широко распространенные детали. Таким образом можно достичь очень хорошей производительности, но при более высокой стоимости.

- Архитектура кластерной системы (способ соединения процессоров друг с другом) в большей степени определяет ее производительность, чем тип используемых в ней процессоров.
- Критическим параметром, влияющим на величину производительности такой системы, является расстояние между процессорами.
- Соединив вместе 10 персональных компьютеров, мы получим систему для проведения высокопроизводительных вычислений.
- Проблема будет состоять в поиске наиболее эффективного способа соединения стандартных средств друг с другом, поскольку при увеличении производительности каждого процессора в 10 раз производительность системы в целом в 10 раз не увеличится.


Схема соединения процессоров в виде плоской решетки




Топология связи 3-х мерный гиперкуб



Топология связи 4-х мерный гиперкуб




Архитектура кольца с полной связью по хордам (Chordal Ring)



Архитектура «Fat-tree»

- Наиболее эффективной является *архитектура* с топологией "толстого дерева" (fat-tree).
- *Архитектура* "fat-tree" (hypertree) была предложена Лейзерсоном (Leiserson) в 1985 году.
- Процессоры локализованы в листьях дерева, в то время как внутренние узлы дерева скомпонованы во внутреннюю *сеть*.
- Поддеревья могут общаться между собой, не затрагивая более высоких уровней сети.

Кластерная архитектура "Fat-tree"



Кластерная архитектура "Fat-tree"

